Informe técnico final

Estimación de la tasa de producción de petróleo a partir de parámetros operativos en el campo Volve

Proyecto integrador de los cursos preparatorios

Maestría en Inteligencia Artificial Aplicada

Universidad Internacional del Ecuador (UIDE)

Autor: Alan Israel López Males

Repositorio: https://github.com/AlanIsrael96/Proyecto-Integrador-UIDE/tree/main

15 de Octubre de 2026

Resumen

Este trabajo estima la tasa diaria de petróleo de los pozos productores del campo Volve, en el mar del Norte, a partir de parámetros operativos: horas en línea, apertura del choke, presión y temperatura en cabeza y diferencial de presión en el choke. Se utilizaron 7.965 registros diarios de producción activa de seis pozos. La partición temporal se estableció con datos de entrenamiento hasta junio de 2015 y datos posteriores para la evaluación.

El primer intento de predecir directamente la producción de petróleo no generalizó (R^2 negativo). Esto se relaciona con el aumento del corte de agua del campo a lo largo del tiempo: las variables operativas explican el líquido producido, pero no la fracción correspondiente al petróleo. Por esta razón, se adoptó un enfoque en dos etapas. Primero, un modelo Random Forest estima el líquido total; después, la tasa de petróleo se calcula mediante un corte de agua de referencia. En el período de prueba, el Random Forest obtuvo $R^2 = 0{,}77$, RMSE = 1.021 BPPD y MAE = 760 BPPD, con un desempeño desigual entre pozos y tendencia a sobreestimar. Los resultados se expresan en unidades de campo (barriles, psi y °F). Además, se desarrollaron un detector de desviaciones basado en reglas de ingeniería orientativas y una interfaz en Streamlit, y se analizaron los riesgos éticos y las limitaciones del trabajo.

1. Introducción

En ingeniería de producción, conocer la tasa de petróleo de cada pozo permite fundamentar decisiones de operación, optimización y seguimiento del yacimiento. La medición continua requiere equipos costosos y los sensores pueden fallar o quedar fuera de servicio. Una alternativa consiste en estimar la tasa a partir de variables operativas que se registran diariamente; este enfoque se conoce como medición virtual de flujo.

Pregunta de investigación. ¿Es posible estimar la tasa diaria de petróleo de los pozos productores de Volve a partir de parámetros operativos y con qué precisión generaliza el modelo a fechas posteriores al período de entrenamiento?

Objetivos del trabajo

- • Limpiar y analizar los datos de producción diaria del campo Volve.
- • Entrenar y comparar modelos de regresión con una partición temporal.
- • Interpretar los resultados e identificar las variables más influyentes.
- • Construir un detector simple de desviaciones y discutir sus límites.
- • Reflexionar sobre los riesgos éticos y las limitaciones del uso de IA en este contexto.

Alcance. El trabajo estima la tasa dadas unas condiciones operativas. No constituye un pronóstico de declinación de producción ni un diagnóstico confirmado de causas. Se trata de un ejercicio académico y no de una herramienta para tomar decisiones operativas.

2. Datos

Se utilizó el archivo de producción del campo Volve, publicado por Equinor junto con sus antiguos socios (ExxonMobil y Bayerngas) como conjunto de datos abierto para investigación y formación. Volve es un campo del mar del Norte que produjo entre 2008 y 2016. La hoja Daily Production Data contiene 15.634 registros diarios y 24 columnas, correspondientes al período entre septiembre de 2007 y diciembre de 2016, para seis pozos productores y pozos inyectores de agua.

Las variables operativas utilizadas fueron las horas en línea (ON_STREAM_HRS), la apertura del choke en porcentaje (AVG_CHOKE_SIZE_P), la presión y la temperatura en cabeza (AVG_WHP_P y AVG_WHT_P), y el diferencial de presión en el choke (DP_CHOKE_SIZE). Como conjunto alternativo, también se probaron la presión y la temperatura de fondo y el diferencial en tubería. La variable de interés fue el volumen diario de petróleo (BORE_OIL_VOL).

Unidades de medida. El archivo original utiliza unidades del Sistema Internacional. Dado que el proyecto se presenta en Ecuador, donde la industria petrolera utiliza unidades de

campo, todos los análisis, gráficos y resultados se convirtieron a barriles estándar por día (BPPD para petróleo, BAPD para agua y BFPD para líquido total; 1 Sm^3 = 6,28981 bbl), presión en psi (1 bar = 14,5038 psi) y temperatura en °F. La apertura del choke se expresa en porcentaje y las horas en línea, en horas. El conjunto de datos no incluye variables de longitud (pies o pulgadas).

Licencia. Los datos se utilizan bajo la Equinor Open Data Licence, que prohíbe su reventa y exige atribuirlos a sus propietarios. Equinor y sus antiguos socios no ofrecen garantías sobre el contenido ni sobre la relevancia de los datos.

3. Metodología

3.1 Limpieza de datos

La inspección inicial permitió identificar cuatro problemas de calidad. A continuación, se presentan las decisiones adoptadas:

- Pozos inyectores. Se conservaron únicamente los pozos productores, ya que los inyectores no producen petróleo.
- Días sin producción. Se descartaron los registros con cero horas en línea o producción de petróleo igual a cero (cerca del 12,5 % de los registros de pozos productores).
- Ceros en sensores de fondo. En 1.923 registros, la presión y la temperatura de fondo eran iguales a cero. Estos valores se interpretaron como lecturas ausentes y se convirtieron en datos faltantes. La presión anular se descartó porque más del 20 % de sus registros estaban faltantes o tenían valor cero.
- Valores inconsistentes. Cuatro registros de producción de agua negativa se ajustaron a cero. El agua se utilizó únicamente como variable derivada y de diagnóstico, no como entrada del modelo.

Tabla 1. Registros tras cada paso de limpieza

Paso	Registros
Filas originales (hoja diaria)	15.634
Solo pozos productores (OP)	9.143
Con horas en línea y petróleo > 0	7.998
Sin faltantes en variables de superficie	7.995
Con corte de agua de referencia disponible (≥ 5 registros previos)	7.965

3.2 Análisis exploratorio

La presión en cabeza (r = 0,64) y el diferencial de presión en el choke (r = 0,59) fueron las variables operativas con mayor correlación con la tasa de petróleo; las demás presentaron correlaciones bajas ($|r| \leq 0{,}23$). A lo largo del tiempo, la tasa de petróleo disminuyó marcadamente en todos los pozos, mientras que el líquido total se mantuvo por más tiempo. Esto coincide con el aumento del corte de agua medio anual: de cerca del 1 % en 2008 pasó a valores de entre 48 % y 77 % desde 2010. En el período de prueba, el promedio llegó al 95 % en el pozo F-14 (Figura 1). La tasa media de petróleo del período de prueba (≈ 2.440 BPPD) fue considerablemente menor que la del período de entrenamiento (≈ 9.435 BPPD).

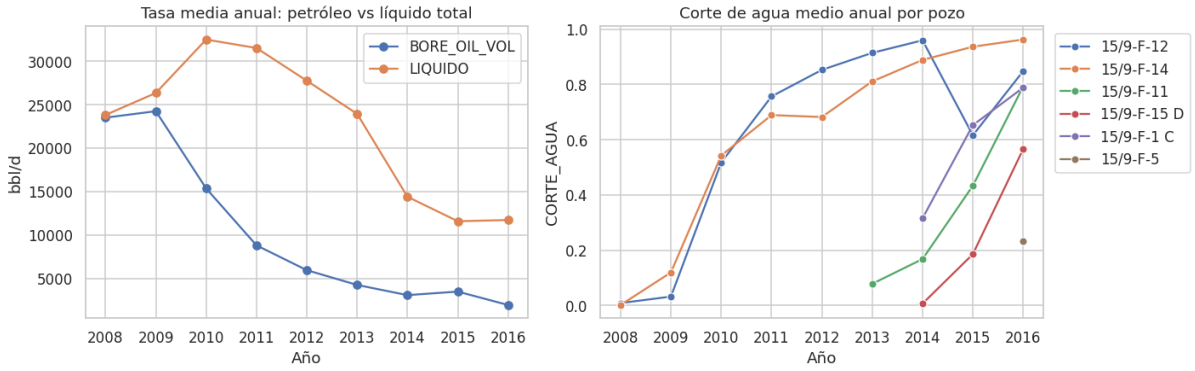


Figura 1. Tasa media anual de petróleo y líquido total (izquierda) y corte de agua medio anual por pozo (derecha).

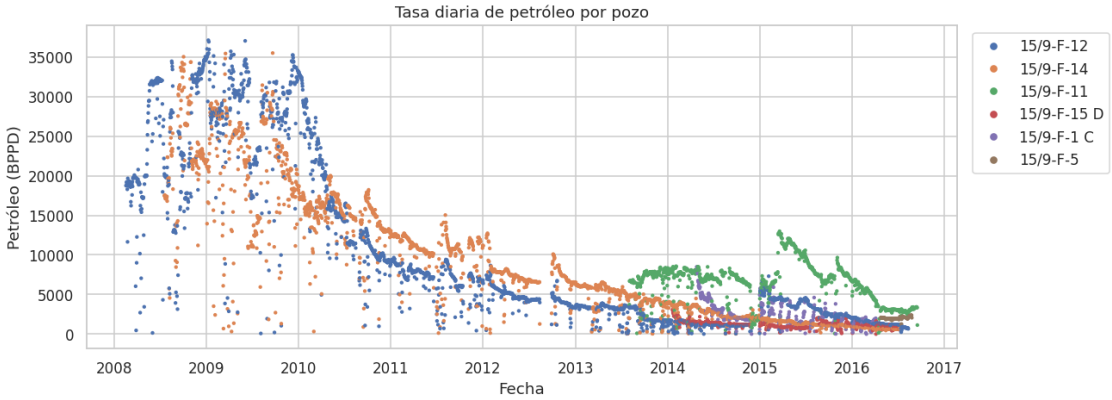


Figura 2. Tasa diaria de petróleo por pozo, 2008–2016.

3.3 Ingeniería de variables

Se calcularon tres variables derivadas: el líquido total (petróleo + agua), el corte de agua diario y un corte de agua de referencia. Este último se definió como la mediana de los 14 registros previos de producción activa del mismo pozo, sin incluir el día evaluado. La referencia utiliza únicamente información pasada y representa información que en campo se obtiene mediante pruebas de pozo o asignación de producción.

3.4 Partición temporal y control de fuga de datos

Debido a que los datos forman una serie temporal, una partición aleatoria habría mezclado días cercanos entre los conjuntos de entrenamiento y prueba y podría haber generado

resultados optimistas. El modelo se entrenó con registros anteriores al 1 de julio de 2015 (6.211 filas, del 17-feb-2008 al 30-jun-2015) y se evaluó con los posteriores (1.754 filas, del 1-jul-2015 al 17-sep-2016). El pozo 15/9-F-5 aparece únicamente en el período de prueba, lo que plantea una prueba exigente de generalización. No se utilizaron como entradas las producciones de gas ni de agua del mismo día, dado que son resultados de la producción.

3.5 Modelos y métricas

Se compararon cuatro modelos: un modelo de referencia que predice la media del conjunto de entrenamiento (dummy), una regresión lineal, un Random Forest (300 árboles y un mínimo de 5 muestras por hoja) y una red neuronal pequeña (MLP con capas de 32 y 16 neuronas). En la red neuronal, el objetivo se estandarizó para que el resultado no dependiera de las unidades. Todos los modelos incluyeron imputación de datos faltantes con la mediana; los modelos lineales y neuronales también utilizaron escalado de variables. La evaluación se realizó con R^2, RMSE y MAE sobre el conjunto de prueba. Se probaron dos conjuntos de variables: solo superficie y superficie más fondo.

3.6 Detector de desviaciones

Se consideró desviación un día cuyo residuo (valor real − valor estimado) superó tres desviaciones robustas, calculadas mediante la desviación absoluta mediana (MAD). Para los días marcados, se aplicaron reglas de ingeniería sencillas que comparan la presión en cabeza, el choke, el diferencial en el choke y el corte de agua con la referencia móvil del pozo. Estas reglas sugieren hipótesis que un ingeniero debe verificar.

3.7 Herramientas

El trabajo se desarrolló en Python con pandas, NumPy, scikit-learn, matplotlib y seaborn. Se utilizó SQLite para consultas SQL de exploración y Streamlit para la interfaz. El

código se organizó en un notebook de Jupyter y se fijó la semilla aleatoria en 42 para facilitar la reproducibilidad.

4. Resultados

4.1 Primer intento: predecir el petróleo directamente

Con las variables de superficie, ninguno de los modelos logró generalizar al período de prueba (Tabla 2). Incluso el mejor modelo, Random Forest, obtuvo un R^2 ligeramente negativo, y la red neuronal presentó un resultado inferior. La explicación propuesta es de carácter físico: el modelo aprendió a partir de un período con alta producción de petróleo y, al aplicarse a un período con un corte de agua elevado, sobreestimó la producción. Las variables operativas explican cuánto líquido produce el pozo, pero no qué fracción corresponde al petróleo.

Tabla 2. Petróleo predicho directamente (variables de superficie, período de prueba)

Modelo	R^2	RMSE (BPPD)	MAE (BPPD)
Random Forest	−0,06	2.180,8	1.739,2
Red neuronal (MLP)	−0,45	2.548,7	1.533,6
Regresión lineal	−5,85	5.539,3	3.894,6
Dummy (media)	−10,92	7.307,3	6.997,0

4.2 Enfoque en dos etapas

En la primera etapa, el modelo estima el líquido total; en la segunda, la producción de petróleo se calcula como líquido estimado × (1 − corte de agua de referencia). Como muestra la Tabla 3, la red neuronal con variables de superficie obtuvo el menor error con la semilla 42 ($R^2 = 0,83$; RMSE = 865 BPPD), seguida del Random Forest ($R^2 = 0,77$; RMSE = 1.021 BPPD; MAE = 760 BPPD, equivalente al 31 % de la tasa media del período). Sin embargo, el resultado de la red neuronal depende de la semilla aleatoria, mientras que Random Forest se mantiene

estable. Por esta razón, se adoptó Random Forest como modelo final y los resultados siguientes corresponden a este modelo. La regresión lineal no generalizó, lo que sugiere una relación no lineal entre las variables operativas y el caudal.

Tabla 3. Enfoque en dos etapas (período de prueba)

Variables	Modelo	R^2 líquido	R^2 petróleo	RMSE	MAE
Superficie	Red neuronal (MLP)	0,88	0,83	865,4	604,3
Superficie	Random Forest	0,68	0,77	1.020,6	760,4
Superficie + fondo	Red neuronal (MLP)	0,78	0,76	1.042,2	705,0
Superficie + fondo	Random Forest	0,72	0,64	1.275,5	828,6
Superficie	Regresión lineal	−0,34	−0,25	2.364,4	1.694,6
Superficie + fondo	Regresión lineal	−0,38	−0,35	2.457,8	1.768,9
Superficie	Dummy (media)	−1,96	−8,21	6.421,1	4.169,0

Notas: RMSE y MAE en BPPD, calculados sobre el petróleo. El dummy es idéntico con ambos conjuntos de variables.

Tres observaciones adicionales:

- **Las variables de fondo no ayudaron.** Con Random Forest, añadirlas mejoró levemente el R^2 del líquido (0,72 frente a 0,68), pero empeoró el del petróleo (0,64 frente a 0,77); con la red neuronal empeoraron ambos. Tienen cerca de 26 % de datos faltantes que se imputaron con la mediana y el pozo F-5 no las tiene.
- **La red neuronal es inestable.** Repetida con cinco semillas, el R^2 del petróleo varió entre 0,45 y 0,89 (RMSE medio de 956 ± 358 BPPD), por lo que su resultado depende demasiado de la semilla y es menos confiable que el Random Forest en este conjunto pequeño.

• **Límite superior.** Si el líquido se conociera exactamente, el método con el corte de agua de referencia alcanzaría $R^2 = 0{,}98$ (RMSE = 302 BPPD). Es decir, la suposición del corte de agua introduce un error pequeño y la mayor parte del error proviene del modelo de líquido.

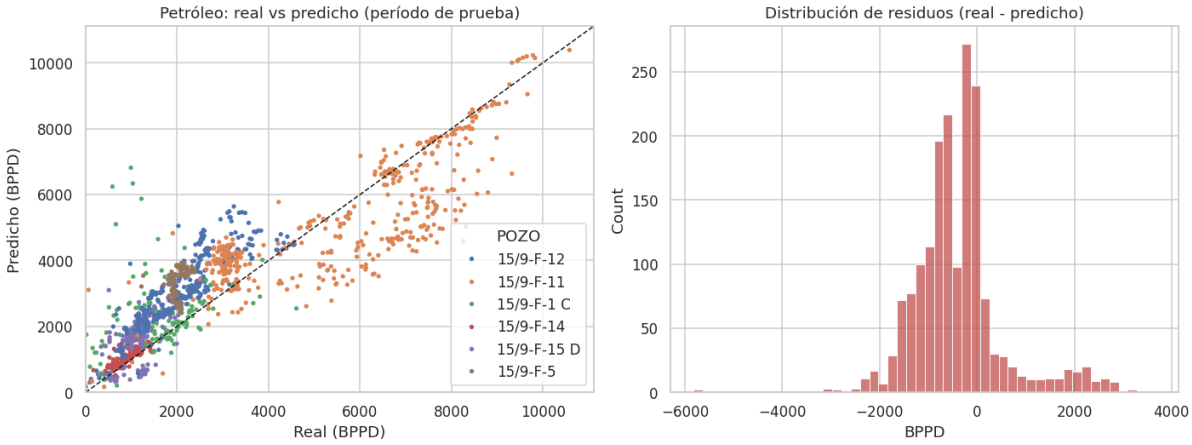


Figura 3. Petróleo real frente a predicho (izquierda) y distribución de residuos (derecha) en el período de prueba.

Los residuos presentan un sesgo: en promedio, el modelo sobreestima la producción de petróleo en unos 395 BPPD. En el 81 % de los días, la predicción supera el valor real, como se aprecia en la cola negativa de la Figura 3.

4.3 Desempeño por pozo

El desempeño global oculta diferencias importantes entre pozos (Tabla 4 y Figura 4). El modelo presenta resultados razonables en F-11 y F-14, pero obtiene R^2 negativo en F-1 C, F-12, F-15 D y F-5. Dentro de cada pozo, la variación de la tasa en el período de prueba es pequeña; por ello, un sesgo casi constante puede producir un R^2 muy negativo. En consecuencia, también se reportan RMSE y MAE. El resultado más desfavorable corresponde a F-5, que no tiene datos en el entrenamiento ($R^2 = -62$, con una sobreestimación media cercana a 1.294 BPPD).

Tabla 4. Desempeño por pozo en el período de prueba (petróleo)

Pozo	Registros	RMSE (BPPD)	MAE (BPPD)	R^2
15/9-F-1 C	134	1.364,6	808,5	−1,81
15/9-F-11	433	1.300,6	1.015,1	0,64
15/9-F-12	405	1.065,3	942,8	−0,50
15/9-F-14	375	189,2	159,9	0,44
15/9-F-15 D	291	740,5	666,2	−3,72
15/9-F-5	116	1.353,6	1.294,0	−62,09

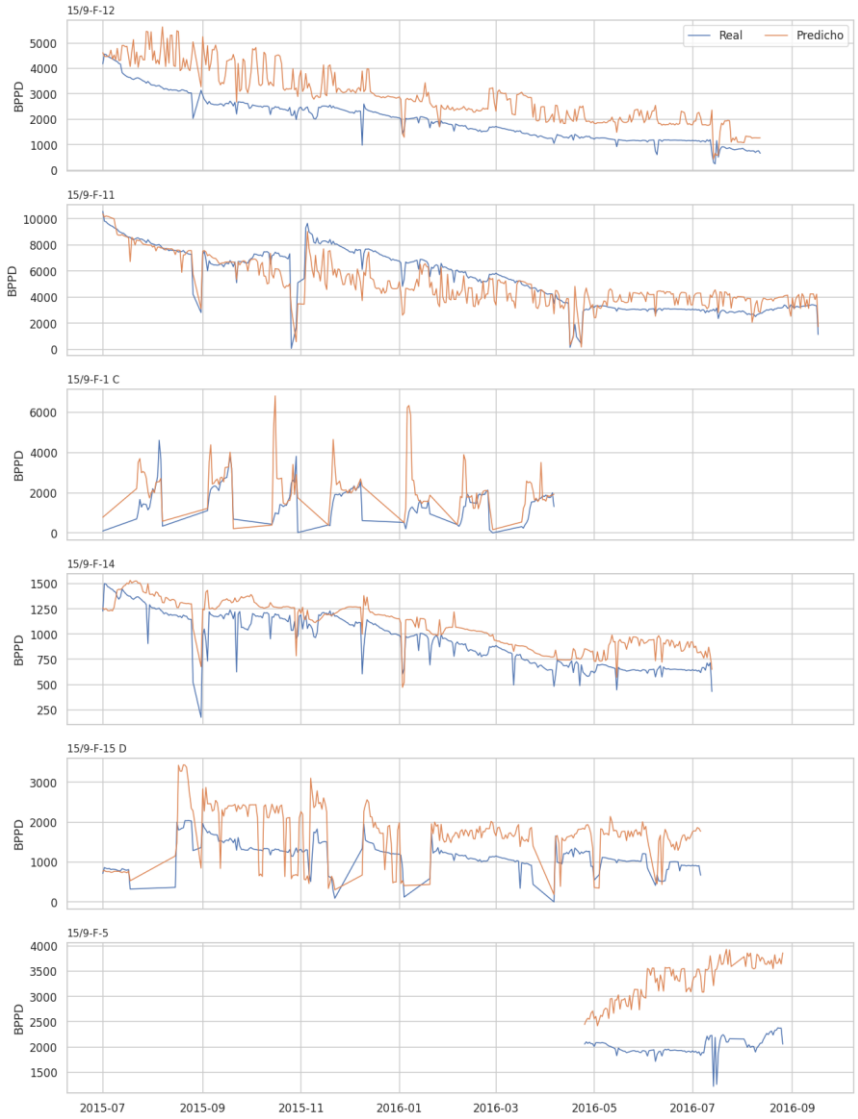


Figura 4. Petróleo real y predicho por pozo en el período de prueba.

4.4 Variables más influyentes

La importancia por permutación del modelo de líquido (Tabla 5 y Figura 5) indica que la temperatura en cabeza es, con diferencia, la variable de mayor importancia, seguida del diferencial de presión en el choke y de la apertura del choke. Es físicamente plausible que, a mayor caudal, el fluido llegue más caliente a superficie. Sin embargo, la importancia mide asociación y no causalidad, y también podría reflejar cambios de condiciones a lo largo del tiempo. Aunque la presión en cabeza es la variable más correlacionada con el petróleo, ocupa

el cuarto lugar en importancia, posiblemente porque comparte información con las demás variables de superficie.

Tabla 5. Importancia por permutación (aumento del RMSE del líquido, BFPD)

Variable	Aumento del RMSE	Desv.
Temperatura en cabeza (AVG_WHT_P)	5.698,7	103,4
Diferencial de presión en el choke (DP_CHOKE_SIZE)	1.213,4	35,4
Apertura del choke (AVG_CHOKE_SIZE_P)	922,4	77,2
Presión en cabeza (AVG_WHP_P)	589,7	55,9
Horas en línea (ON_STREAM_HRS)	149,4	29,3

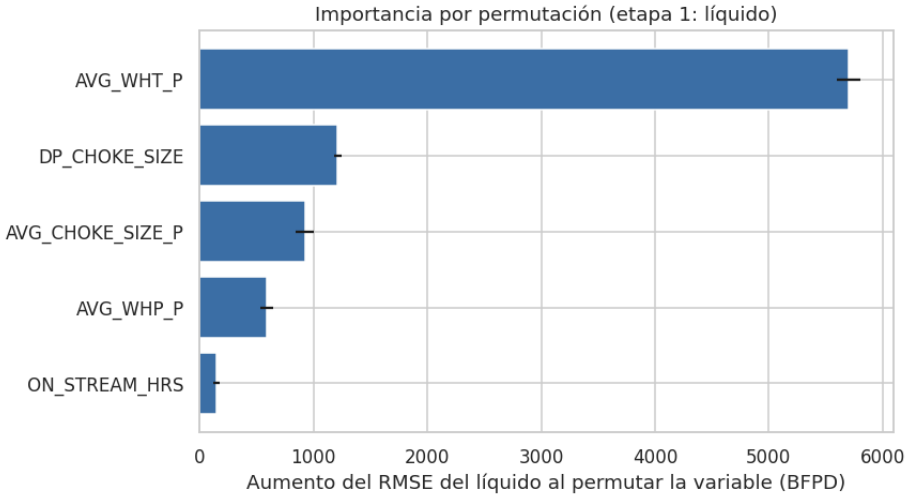


Figura 5. Importancia por permutación de las variables operativas.

4.5 Detector de desviaciones

La desviación robusta de los residuos fue de 594 BPPD, con un umbral de ±1.782 BPPD. Con este criterio se marcaron 139 de los 1.754 días de prueba (7,9 %). La mayoría (85 días) corresponde a una producción superior a la esperada. Entre los casos de producción inferior, las reglas sugirieron un aumento del corte de agua en 11 días y otras causas en solo 2; en 41 días no se generó una hipótesis (Tabla 6).

Tabla 6. Hipótesis sugeridas por las reglas para los días marcados

Hipótesis orientativa	Días
Producción mayor a la esperada: revisar medición o cambios de choke	85
Sin hipótesis por reglas: revisar históricos del pozo	41
Caída con aumento del corte de agua (entrada de agua, conificación o emulsión)	11
Aumento del diferencial en el choke (posible restricción o taponamiento)	1
Caída de presión en cabeza con choke estable (restricción o pérdida de integridad)	1

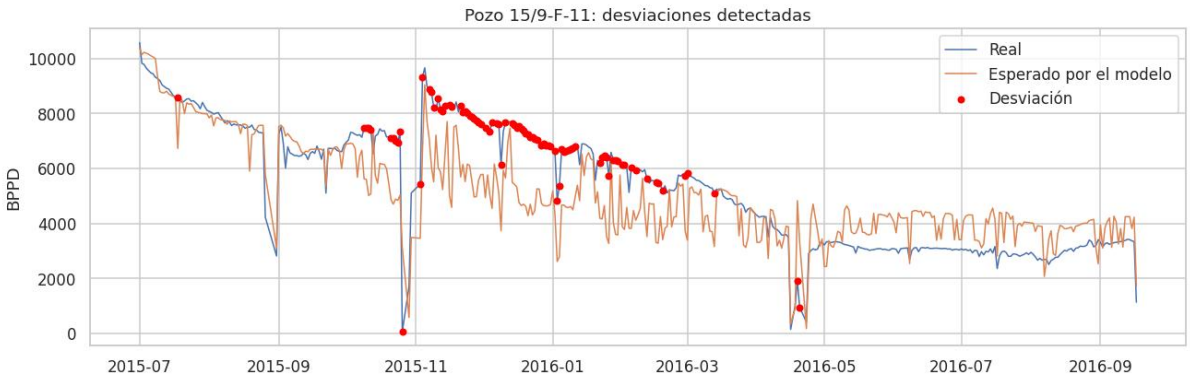


Figura 6. Desviaciones detectadas (puntos rojos) frente al valor esperado por el modelo en un pozo del período de prueba.

Estas hipótesis son únicamente orientativas. El conjunto de datos no incluye eventos etiquetados (emulsión, fugas o recirculación), por lo que el sistema no puede confirmar ninguna causa. Además, los umbrales de las reglas se fijaron mediante criterio experto y el umbral de desviación se calibró con los mismos datos de prueba. Para un uso real, sería necesario calibrarlos con un período de validación independiente y con apoyo de especialistas.

4.6 Interfaz de usuario

Se desarrolló una aplicación en Streamlit (archivo app.py) con tres secciones: una estimación puntual, en la que el usuario ajusta las variables operativas y el corte de agua para

obtener estimaciones de líquido, petróleo y agua (con comparación opcional frente a un valor real medido y una alerta de desviación); un explorador del historial de producción por pozo; y una descripción del modelo y sus limitaciones.

5. Discusión

Comparación con las curvas de declinación. Este modelo y las curvas de declinación (Arps y variantes) responden a preguntas distintas. La declinación ajusta la tendencia de la tasa en función del tiempo y la extrapola para estimar reservas o producción futura; es simple, interpretable y constituye la referencia habitual en los reportes de reservas. El enfoque de aprendizaje automático presentado aquí estima la tasa a partir de condiciones operativas y puede incorporar efectos del choke y de la presión que una curva de un solo parámetro no contempla. Sin embargo, extrapola mal fuera del rango observado, requiere datos y no garantiza coherencia física. No se realizó una comparación numérica con una curva de declinación; esta comparación queda como trabajo futuro.

Aprendizajes del primer intento. El resultado negativo del enfoque directo fue informativo: mostró que el problema tenía una estructura física —el petróleo es una fracción del líquido— que el modelo no podía aprender a partir de las variables disponibles. Incorporar esa estructura mediante dos etapas permitió mejorar sustancialmente el resultado.

Limitaciones principales

- • Un solo campo y seis pozos; el modelo no debe aplicarse a otros campos sin revalidar.
- • Desempeño irregular entre pozos y sesgo a sobreestimar; un buen R^2 global no garantiza buenas estimaciones en cada pozo.
- • Dependencia de un corte de agua de referencia conocido; si cambia bruscamente (por ejemplo, irrupción de agua), la estimación se sesga.

- • Partición única entre entrenamiento y prueba y sin ajuste sistemático de hiperparámetros.
- • Calidad de los datos: ceros y faltantes en sensores y poca historia en pozos recientes.

6. Reflexiones éticas sobre el uso de IA

• Uso responsable y supervisión humana. Una estimación no sustituye la medición real ni el criterio de un ingeniero. Las decisiones operativas, económicas o de seguridad no deberían basarse únicamente en este modelo; cualquier alerta requiere validación humana.

• Correlación y causalidad. El modelo muestra asociaciones, no causas. Las hipótesis del detector podrían inducir a error si se interpretan como diagnósticos, lo que podría llevar a intervenciones innecesarias o a pasar por alto el problema real.

• Sesgos y representatividad de los datos. Los datos provienen de un solo campo y de un período concreto. Las condiciones cambiaron con el tiempo y algunos pozos tienen poca historia. Por ello, un modelo aplicado a otros contextos podría fallar sin advertirlo.

• Calidad de los datos y transparencia. Se documentaron las decisiones de limpieza, la partición y las métricas, incluidos los resultados negativos. También se fijó la semilla aleatoria para facilitar la reproducción del trabajo.

• Supuestos explícitos. La estimación depende de un corte de agua de referencia. Este supuesto y sus riesgos se declaran de forma explícita.

• Licencia y atribución. Los datos pertenecen a Equinor y a los antiguos socios de Volve, y se utilizan bajo su licencia abierta con fines de aprendizaje, con atribución a la fuente.

• Mantenimiento. En un uso real, el modelo requeriría monitoreo continuo, reentrenamiento ante cambios en el pozo y una persona responsable de validar las alertas.

• Uso de herramientas de IA. [Completa aquí, con tus propias palabras, si utilizaste herramientas de IA como apoyo y para qué tareas. Confirma también que comprendes el código y los resultados presentados.]

7. Conclusiones y trabajo futuro

1. • Predecir el petróleo directamente a partir de parámetros operativos no generalizó en el tiempo, porque el corte de agua del campo crece y las variables operativas no lo capturan.
2. • Un enfoque en dos etapas (líquido estimado con Random Forest y corte de agua de referencia) con el Random Forest alcanzó $R^2 = 0,77$ y MAE = 760 BPPD en el período de prueba, frente a valores negativos del enfoque directo.
3. • La regresión lineal no fue adecuada y las variables de fondo no mejoraron el resultado; la red neuronal, aunque llegó a $R^2 = 0,83$ con una semilla, fue inestable (R^2 entre 0,45 y 0,89 según la semilla).
4. • El desempeño es desigual entre pozos y el modelo tiende a sobreestimar; en un pozo sin historia previa (F-5) el error fue alto.
5. • El detector de desviaciones sirve como alerta, pero sus hipótesis son solo orientativas por la ausencia de eventos etiquetados.

• Trabajo futuro: comparar con curvas de declinación; ajustar hiperparámetros y validar con varias particiones temporales; incorporar más pozos o campos; usar conjuntos con eventos etiquetados (por ejemplo, el dataset 3W de Petrobras) para pasar de la detección al diagnóstico supervisado; y estimar la incertidumbre de las predicciones.

Referencias

Equinor. (s. f.). Volve field data set. Equinor Open Data Licence. https://www.equinor.com/energy/volve-data-sharing

Documentación de pandas, scikit-learn, matplotlib, seaborn y Streamlit. (s. f.). [Completar con los títulos y enlaces de la documentación consultada.]

Anexo. Reproducibilidad

El repositorio contiene el notebook principal (proyecto_integrador_volve.ipynb), la aplicación (app.py), el conjunto de datos (carpeta data), el modelo entrenado (carpeta models), los gráficos (carpeta figures) y este informe (carpeta docs). Para ejecutarlo, se instalan las dependencias con pip install -r requirements.txt; luego, se abre el notebook y se ejecutan todas las celdas. La interfaz se inicia con streamlit run app.py. Las instrucciones completas se encuentran en el archivo README.md.